

TECH CHALLENGE

FASE 3

FIAP

Grupo:

Armando Caliari Silva	rm372117
Caike Herbe Jauch Soares	rm371123
Gabriel Santos de Oliveira Arruda	rm371178
Gustavo Ferreira da Silva Santana	rm370545
Kauan Lucas Gomes Jardim	rm370438

Data: 23/08/2026

Sumário

1. COMPREENSÃO DO PROBLEMA.....	3
1.1 Contexto do projeto.....	4
1.2 Objetivo.....	4
1.3 Perguntas de negócio.....	4
2. BASE DE DADOS E ESCOPO.....	4
2.1 Fonte dos dados.....	4
2.2 Edições utilizadas.....	5
3. ARQUITETURA DA SOLUÇÃO AWS.....	5
3.1 Serviços utilizados.....	5
3.2 Fluxo dos dados.....	6
3.2.1 Ingestão e Camada Bronze.....	6
3.2.2 Transformação e Camada Silver.....	6
3.2.3 Transformação e Camada Gold.....	6
3.2.4 Catalogação dos Dados.....	7
3.2.5 Consultas com Amazon Athena.....	7
3.2.6 Visualização no Power BI.....	7
4. PIPELINE DE ENGENHARIA DE DADOS.....	8
4.1 Camada Bronze.....	8
4.2 Transformação de Bronze para Silver.....	8
4.3 Camada Silver.....	8
4.4 Transformação de silver para Gold.....	9
4.5 Camada Gold.....	9
4.6 Catalogação e consultas.....	9
5. TRATAMENTOS E REGRAS DE TRANSFORMAÇÃO.....	9
5.1 Harmonização dos schemas.....	9
5.2 Tratamento de textos e valores nulos.....	9
5.3 Padronização de categorias.....	10
5.4 Remuneração.....	10
5.5 Tecnologias e campos multisseleção.....	10
5.6 Inteligência Artificial.....	10
5.7 Deduplicação e particionamento.....	10
6. ANÁLISES E RESULTADOS.....	10
6.1 Estrutura do mercado brasileiro de dados.....	10
6.2 Perfis profissionais mais valorizados.....	12
6.3 Diversidade de gênero.....	13
6.4 Tecnologias mais adotadas.....	14
6.5 Adoção e impacto de Inteligência Artificial.....	15
6.6 Diferenças por região, senioridade e modelo de trabalho.....	16
6.7 Oportunidades e desafios.....	17
7. PRINCIPAIS INSIGHTS.....	17
8. RECOMENDAÇÕES ESTRATÉGICAS.....	18
9. CONCLUSÃO.....	19
10. REFERÊNCIAS BIBLIOGRÁFICAS.....	20
11. LINKS DE ACESSO.....	20

1. COMPREENSÃO DO PROBLEMA

O presente Tech Challenge simula a atuação de uma equipe de Big Data & Analytics responsável por apoiar uma instituição financeira que pretende expandir suas áreas de Dados, Analytics e Inteligência Artificial. Para isso, é necessário compreender o cenário atual do mercado brasileiro, identificando características dos profissionais, tecnologias utilizadas, remuneração, senioridade, modelos de trabalho e adoção de Inteligência Artificial.

O cenário corporativo brasileiro vive o chamado “paradoxo dos dados”: apesar do grande volume de informações disponíveis, muitas empresas ainda enfrentam dificuldades para transformá-las em valor. Embora 73% das empresas brasileiras sejam orientadas por dados, apenas 28% conseguem tratá-los adequadamente, enquanto 47% ainda são classificadas como “novatas de dados”. Além disso, apenas 22% utilizam dados de forma estratégica, evidenciando um amplo espaço para evolução da maturidade analítica (Instituto Information Management, 2021)

Nesse contexto, as empresas esperam que dados e Inteligência Artificial (IA) contribuam principalmente para aumentar eficiência, produtividade, capacidade de decisão e retorno financeiro. Organizações com maior maturidade em dados apresentam maior capacidade de responder às mudanças do mercado e transformar informações em vantagens competitivas. Neste contexto, percebe-se que o mercado de data analytics brasileiro apresenta forte perspectiva de crescimento, impulsionado pela necessidade de aumentar a eficiência dos negócios e utilizar tecnologias conectadas para gerar insights relevantes (Insper, 2025).

A evolução tecnológica acompanha essa mudança de expectativa. Inicialmente, ferramentas de Business Intelligence (BI) eram utilizadas principalmente para analisar dados históricos e compreender o desempenho passado e presente. Com a evolução da ciência de dados, machine learning e IA, as empresas passaram a buscar análises preditivas e automatizadas, capazes de antecipar cenários e apoiar decisões futuras. Atualmente, essa evolução avança para aplicações mais integradas, envolvendo IA generativa, agentes de IA, automação de processos e sistemas capazes de conectar dados, aplicações e fluxos de trabalho. Ao mesmo tempo, o crescimento dessas tecnologias aumenta a importância de governança, segurança, privacidade e soberania dos dados e da IA.

Entre as principais tendências do mercado está justamente a integração cada vez maior entre dados, IA e operações empresariais. Em vez de aplicações isoladas, a expectativa é que a IA seja incorporada aos processos de negócio, apoiando decisões, automatizando tarefas e permitindo respostas mais rápidas às mudanças do mercado. Esse movimento também amplia a necessidade de profissionais capazes de conectar tecnologia e estratégia empresarial.

Nesse cenário, os perfis interdisciplinares ganham destaque. Cientistas e analistas de dados continuam entre os profissionais mais demandados: as buscas por vagas de cientista de dados cresceram quase 4.000% no Brasil em 2023 (Insper, 2025). Entretanto, a valorização profissional não se limita ao domínio técnico. As empresas procuram pessoas capazes de combinar

programação, estatística, matemática, conhecimento de IA e visão de negócios, traduzindo análises em decisões práticas. O próprio Insper destaca a crescente importância de profissionais que conciliem conhecimento técnico e visão estratégica, incluindo funções como especialistas em ética de IA e “tradutores de dados”, capazes de comunicar análises de maneira útil para diferentes áreas da empresa (Insper, 2025).

Assim, o mercado caminha para um modelo no qual dados deixam de ser apenas recursos para análise e passam a constituir ativos estratégicos: As empresas que conseguirem integrar dados, IA, pessoas e processos terão maior capacidade de transformar informação em produtividade, inovação e vantagem competitiva.

1.1 Contexto do projeto

A pesquisa State of Data Brasil foi utilizada como principal fonte de informações para a construção da solução. O projeto contempla não apenas a análise dos dados, mas também a implementação de um fluxo completo em ambiente Cloud, desde a ingestão das bases até a disponibilização de informações tratadas e agregadas para consultas e visualizações.

1.2 Objetivo

O objetivo é construir uma solução analítica em AWS capaz de organizar, tratar e consolidar as três edições mais recentes da pesquisa State of Data Brasil, permitindo gerar indicadores e análises que apoiem decisões relacionadas à contratação, capacitação de profissionais e investimentos em Dados e Inteligência Artificial.

1.3 Perguntas de negócio

- Como está estruturado o mercado brasileiro de Dados?
- Quais perfis profissionais são mais valorizados pelo mercado?
- Qual é o cenário de diversidade de gênero nas carreiras de dados?
- Quais tecnologias apresentam maior adoção entre os profissionais?
- Qual é o índice de adoção de Inteligência Artificial e seu impacto?
- Existem diferenças relevantes entre regiões, senioridades ou modelos de trabalho?
- Quais oportunidades e desafios podem ser identificados para empresas que desejam investir em Dados e Inteligência Artificial?

2. BASE DE DADOS E ESCOPO

2.1 Fonte dos dados

Foram utilizadas as pesquisas State of Data Brasil disponibilizadas pela comunidade Data Hackers. As bases possuem informações relacionadas ao perfil dos profissionais, formação, experiência, remuneração, tecnologias, modelos de trabalho e adoção de Inteligência Artificial. As três pesquisas não possuem exatamente o mesmo schema. Algumas perguntas apresentam nomes, códigos ou semânticas diferentes entre os anos. Por isso, foi necessária uma etapa de

harmonização para permitir a comparação temporal sem criar equivalências artificiais para informações que não são diretamente comparáveis.

2.2 Edições utilizadas


Tabela 1 - Edições utilizadas nas tabelas de cada ano

Edição	Uso no projeto
2023	Base Bronze e consolidação na Silver
2024	Base Bronze e consolidação na Silver
2025	Base Bronze e consolidação na Silver

3. ARQUITETURA DA SOLUÇÃO AWS

A arquitetura foi estruturada como um Data Lake em camadas Bronze, Silver e Gold. O processamento foi realizado com AWS Glue e PySpark, os dados foram armazenados em Amazon S3, catalogados no AWS Glue Data Catalog e consultados por meio do Amazon Athena. As visualizações podem ser consumidas no power BI.

Figura 1 - Arquitetura da solução AWS



3.1 Serviços utilizados

Tabela 2 - Serviços da amazon AWS utilizados

Serviço	Finalidade
Amazon S3	Armazenamento das camadas Bronze, Silver e Gold
AWS Glue	Ingestão dos arquivos da Landing Zone para a camada Bronze e execução dos processos de transformação das camadas Silver e Gold.
Glue PySpark / Spark	Processamento distribuído, limpeza e agregações
Glue Data Catalog	Catalogação e disponibilização lógica das tabelas
Amazon Athena	Consultas SQL sobre as tabelas catalogadas
Power BI	Visualização e apoio ao storytelling analítico

3.2 Fluxo dos dados

3.2.1 Ingestão e Camada Bronze

Os arquivos CSV das três edições da pesquisa State of Data Brasil foram inicialmente carregados manualmente no Amazon S3, em uma área de entrada denominada Landing Zone. A partir dessa área, foi utilizado o AWS Glue Studio, por meio do recurso Visual ETL, para ler os arquivos da Landing Zone e gravá-los na Camada Bronze do Data Lake, também armazenada no Amazon S3. Nessa etapa, o Glue foi utilizado como ferramenta de ingestão e movimentação dos dados entre as áreas do Data Lake.

Na camada Bronze, os dados são mantidos com estrutura próxima ao formato original das fontes, sem aplicação de transformações analíticas significativas. O objetivo é preservar os dados ingeridos e disponibilizá-los para as etapas posteriores de tratamento e harmonização.

3.2.2 Transformação e Camada Silver

Após a disponibilização das três pesquisas na Camada Bronze e sua catalogação no AWS Glue Data Catalog, os dados passaram a ser processados utilizando AWS Glue com PySpark.

Como as pesquisas dos diferentes anos possuem diferenças em seus schemas, nomes de colunas e formatos de resposta, foi necessário realizar um processo de padronização e harmonização dos dados. Entre as principais atividades realizadas nessa etapa estão:

- Padronização dos nomes das colunas;
- Ajuste e harmonização dos dados entre as diferentes edições da pesquisa;
- Tratamento de valores inconsistentes;
- Padronização de categorias e respostas;
- Correção de formatos de dados;
- Criação de uma estrutura consolidada para permitir análises comparativas entre os anos.

Após o processamento, os dados tratados são armazenados novamente no Amazon S3, formando a Camada Silver.

3.2.3 Transformação e Camada Gold

A partir dos dados consolidados na camada Silver, um novo processo de transformação é executado por meio do AWS Glue com PySpark.

Essa etapa tem como objetivo preparar os dados especificamente para o consumo analítico e para responder às perguntas de negócio do projeto. São realizadas transformações, agregações e cálculos para gerar indicadores relacionados, por exemplo, à:

- Estrutura do mercado brasileiro de Dados;
- Perfil e senioridade dos profissionais;
- Remuneração;

- Diversidade de gênero;
- Tecnologias utilizadas;
- Modelos de trabalho;
- Adoção de Inteligência Artificial;
- Diferenças entre regiões e perfis profissionais.

Os resultados são armazenados no Amazon S3, compondo a Camada Gold. Diferentemente das camadas anteriores, os dados da Gold já estão estruturados e agregados para atender diretamente às necessidades de análise e geração de indicadores.

3.2.4 Catalogação dos Dados

Durante o processo, o AWS Glue Data Catalog é utilizado para realizar a catalogação e o gerenciamento dos metadados das tabelas presentes nas diferentes camadas do Data Lake.

O catálogo permite que os dados armazenados no Amazon S3 sejam reconhecidos como tabelas estruturadas e possam ser consultados utilizando ferramentas analíticas. Dessa forma, são mantidas referências às tabelas das camadas Bronze, Silver e Gold.

3.2.5 Consultas com Amazon Athena

Os dados da Camada Gold são disponibilizados para consulta por meio do Amazon Athena.

O Athena permite realizar consultas utilizando SQL diretamente sobre os dados armazenados no Amazon S3, sem a necessidade de carregar os dados em um banco de dados tradicional.

Por meio do Amazon Athena, as tabelas catalogadas são consultadas utilizando SQL, permitindo validar os dados e disponibilizar os indicadores para análises e visualizações. Os resultados das consultas executadas pelo Athena são armazenados em um bucket específico no S3 destinado aos resultados do Athena.

3.2.6 Visualização no Power BI

Por fim, o Power BI é conectado ao ambiente analítico para consumir os dados e disponibilizá-los por meio de dashboards.

Os dashboards permitem analisar os principais indicadores gerados a partir das três edições da pesquisa State of Data Brasil, facilitando a identificação de tendências e padrões do mercado brasileiro de Dados e Inteligência Artificial.

4. PIPELINE DE ENGENHARIA DE DADOS

4.1 Camada Bronze

A Landing Zone representa o ponto inicial de entrada dos arquivos no Data Lake, recebendo manualmente os arquivos CSV das três edições da pesquisa. Em seguida, por meio do AWS Glue Studio com Visual ETL, esses arquivos são ingeridos e gravados na camada Bronze. As três bases resultantes são posteriormente disponibilizadas no AWS Glue Data Catalog em tabelas separadas.

Tabela 3 - Tabelas bronze

Tabela Bronze	Descrição
workspace.tb_survey_2023	Pesquisa State of Data 2023
workspace.tb_survey_2024	Pesquisa State of Data 2024
workspace.tb_survey_2025	Pesquisa State of Data 2025

4.2 Transformação de Bronze para Silver

O notebook “01_raw_to_silver.ipynb” realiza a seleção das variáveis necessárias, harmoniza colunas entre os anos, trata valores nulos, padroniza categorias e une as três edições em uma única estrutura de nível de respondente.

- Seleção e renomeação das variáveis relevantes.
- Harmonização dos schemas de 2023, 2024 e 2025.
- Tratamento de strings vazias e valores equivalentes a nulo.
- Padronização de cargo, senioridade e modelo de trabalho.
- Criação de salário estimado a partir das faixas salariais.
- Classificação de adoção de Inteligência Artificial.
- Reconstrução de campos multisseleção quando necessário.
- União dos três anos e remoção de duplicatas exatas.
- Escrita em Parquet e particionamento por ano.

4.3 Camada Silver

A Silver mantém uma linha por respondente e concentra as variáveis já tratadas e harmonizadas. Essa camada preserva a possibilidade de criar novas análises cruzadas antes das agregações executivas.

Tabela 4 - Tabelas silver

Objeto	Descrição
workspace.tb_state_of_data_silver	Tabela consolidada e harmonizada dos três anos.
Particionamento	ano=2023, ano=2024 e ano=2025.
Formato	Parquet.

4.4 Transformação de silver para Gold

A transformação “02_silver_to_gold.ipynb” converte os dados no nível do respondente em indicadores agregados, organizados por tema. São aplicadas operações como groupBy, count, avg, percentile_approx, split e explode para produzir dados prontos para consultas e visualizações.

4.5 Camada Gold

Tabela 5 - Tabelas gold

Tabela Gold	Finalidade
tb_gold_mercado	Estrutura do mercado, cargos, senioridade, experiência e remuneração.
tb_gold_diversidade	Distribuição de gênero e comparações por perfil.
tb_gold_tecnologias	Adoção de linguagens, bancos, cloud e ferramentas de BI.
tb_gold_ia	Adoção, prioridade e resultados relacionados à IA.
tb_gold_segmentacoes	Comparações por região, senioridade e modelo de trabalho.
tb_gold_desafios	Desafios de gestão e barreiras relacionadas à adoção de IA.

4.6 Catalogação e consultas

As tabelas Silver e Gold são registradas no database workspace do AWS Glue Data Catalog. A partir dessa catalogação, o Amazon Athena permite realizar consultas SQL diretamente sobre os arquivos armazenados no S3.

5. TRATAMENTOS E REGRAS DE TRANSFORMAÇÃO

5.1 Harmonização dos schemas

Foi criado um mapeamento por edição da pesquisa para identificar perguntas equivalentes e convertê-las em nomes lógicos padronizados na Silver. Campos inexistentes em determinado ano são mantidos como NULL quando necessário para permitir a união dos DataFrames.

5.2 Tratamento de textos e valores nulos

Valores como strings vazias, nan, none, null e n/a são normalizados para NULL. Também são aplicados ajustes simples de espaços e limpeza de textos para reduzir inconsistências de comparação.

5.3 Padronização de categorias

- Cargo: criação de grupo_cargo para concentrar cargos semelhantes em categorias analíticas.
- Senioridade: harmonização para níveis comparáveis entre as edições.
- Modelo de trabalho: agrupamento em categorias como Presencial, Híbrido e Remoto.

5.4 Remuneração

Para permitir comparações quantitativas, foi criada a variável salario_estimado a partir das faixas salariais da pesquisa. Para intervalos fechados, foi utilizado o ponto médio entre os limites inferior e superior. Nas faixas abertas superiores (“acima de R\$ X”), foi adotado o limite inferior informado como estimativa conservadora. Para as faixas inferiores (“menos de R\$ X”), foi utilizada metade do limite superior. Portanto, os valores apresentados representam estimativas e não salários individuais exatos.

5.5 Tecnologias e campos multisseleção

Respostas relacionadas a linguagens, bancos de dados, cloud e ferramentas de BI são preservadas na Silver. Na Gold, os campos multisseleção são separados por item com split e explode para permitir a contagem de usuários e o cálculo de percentuais de adoção.

5.6 Inteligência Artificial

Adoção de Inteligência Artificial: a utilização de IA/LLMs foi identificada a partir das respostas referentes ao uso dessas ferramentas. Respondentes que indicaram pelo menos uma ferramenta de IA/LLM foram classificados como “Utiliza”, enquanto aqueles que não indicaram utilização foram classificados como “Não utiliza”. A partir dessa classificação foi calculado o percentual de adoção por ano e por diferentes segmentações, como senioridade e modelo de trabalho.

5.7 Deduplicação e particionamento

A deduplicação remove apenas registros completamente idênticos. As tabelas analíticas são gravadas em Parquet e organizadas por ano, permitindo consultas e comparações temporais com menor complexidade.

6. ANÁLISES E RESULTADOS

6.1 Estrutura do mercado brasileiro de dados

A distribuição dos profissionais por cargo e por senioridade (base 2025, camada Gold - tb_gold_mercado) revela o cenário atual do mercado de dados no Brasil:

Figura 2 - Gráficos de distribuição de profissionais por cargo e por senioridade (2025)





Figura 3 - Gráfico da evolução de profissionais por cargo (2023 - 2025)



Percebe-se que os cargos de analista de dados (24,0%) e engenheiro/cientista de dados (17,2% e 16,9%, respectivamente) concentram a maior parte da força de trabalho. A distribuição por senioridade reforça essa percepção de maturidade. 65,3% dos profissionais encontram-se nos níveis Pleno ou Sênior, enquanto 20,7% estão no nível Júnior, sugerindo que o mercado já possui uma base significativa de profissionais capazes de atuar de forma mais autônoma.


Por outro lado, profissionais especializados em machine learning e inteligência artificial representam uma parcela significativamente menor do mercado, correspondendo a 4,2% em 2025.

Embora essa participação seja menor quando comparada às funções mais tradicionais, o resultado também evidencia uma possível oportunidade de especialização para novos profissionais.

Nesse sentido, os dados sugerem que profissionais que desenvolverem competências em machine learning, inteligência artificial e suas aplicações aos negócios podem encontrar um espaço de diferenciação em um mercado no qual essas especializações ainda possuem menor representatividade, estão em crescimento lento e possuem salários altos quando comparado com as demais áreas analisadas. Para instituições que pretendem ampliar seus investimentos em Dados e IA, essa diferença também pode indicar a necessidade de formação e desenvolvimento de novos talentos, criando um pipeline de profissionais especializados para atender às demandas futuras.

6.2 Perfis profissionais mais valorizados

A comparação de remuneração média e mediana por cargo e por senioridade (2025) evidencia quais perfis concentram maior valor de mercado à luz das classificações apresentadas na seção anterior.



Machine Learning/IA é o cargo mais bem remunerado (média de R\$18.561, mediana de R\$18.000), seguido por engenharia de dados (média de R\$14.319). Esses dois cargos também estão entre os menos representados no mercado, o que pode ser interpretado como a “Lei da Oferta e Demanda”: quando a oferta de profissionais com determinadas competências é relativamente menor diante da demanda das empresas, tende a existir maior pressão para valorização desses profissionais, resultando em níveis salariais mais elevados.


Por outro lado, business intelligence apresenta a menor remuneração média, de R\$ 7.538, apesar de possuir uma participação maior no mercado, cenário que pode estar relacionado a uma oferta relativamente mais ampla de profissionais com competências semelhantes e,

consequentemente, a uma menor pressão sobre os salários. Essa proporção aponta que uma concentração de profissionais em determinadas competências pode reduzir sua diferenciação e seu poder de negociação, enquanto habilidades mais especializadas e menos disseminadas, como machine learning e IA, tendem a apresentar maior valorização quando acompanhadas de demanda empresarial. Por senioridade, um especialista/staff+ ganha, em média, 4,7 vezes mais que um Júnior (R\$19.685 vs. R\$4.153), reforçando que investimento em capacitação técnica avançada (especialmente em ML/IA e engenharia de dados) é o caminho mais direto para reter e evoluir talentos internos com menor custo de contratação externa.

6.3 Diversidade de gênero

A distribuição por gênero ao longo das três edições da pesquisa e o gap salarial por cargo (2025) permitem avaliar alguns aspectos de representatividade e a equidade de remuneração no setor.

Figura 5 - Gráficos de distribuição por gênero (2023-2025) e gap salarial médio por cargo



Nota-se que a participação feminina já era baixa em 2023 e, ainda assim, vem em decréscimo, saindo de 24,4% para 21,9%. Um estudo realizado pela CNN em 2023 acerca de mulheres nas áreas de tecnologia (CNN Brasil, 2023) indica o aumento do público feminino nessa área, porém, analisando o recorte das carreiras analisadas neste trabalho, especificamente, o cenário é diferente. Isso se dá pelas barreiras enfrentadas pelas mulheres no que tange a falta de incentivo, vencimento de preconceito e falta de equiparação salarial.


Quando ao salário, o gap salarial também não é uniforme: chega a 38,6% em Machine Learning/IA e 31,3% em engenharia de dados, exatamente os cargos mais bem pagos identificados na seção 6.2, enquanto business intelligence, que é a carreira com menor salário e em decréscimo de profissionais no mercado de trabalho, é a única em que a média do salário feminino é maior

que o masculino. Isso mostra a falta de incentivo à inclusão de mulheres neste mercado, uma vez que o público é minoritário mas, ainda assim, não são atraídos por ofertas de trabalho mais atrativas financeiramente.

6.4 Tecnologias mais adotadas


Abaixo, o ranking de linguagens, bancos de dados, plataformas de cloud e ferramentas de BI (2025) mostra o "stack" tecnológico predominante entre os profissionais de dados:

Figura 6 - Gráficos das top tecnologias por categoria: linguagem, banco de dados, Cloud e BI (2025)



Na área de dados e machine learning, python (92,3%) e SQL (84,3%) são praticamente padrão de mercado, formando a base técnica mínima esperada de qualquer contratação. Em bancos de dados não há um vencedor absoluto (PostgreSQL lidera com apenas 36,8%, seguido de perto por SQL Server, databricks e S3), indicando ambientes heterogêneos e multi-plataforma nas empresas. Em cloud, a AWS lidera (49,4%), mas azure (35,7%) tem relevância particular para o setor financeiro, dado seu histórico de adoção em bancos. Em BI, o power BI é dominante (60,6%), o que deve orientar prioridades de padronização de ferramentas e de capacitação técnica da instituição.

Figura 7 - Uso de tecnologias de 2023 a 2025




A presença de Databricks (32,9%) e Amazon S3 (28,8%) revela uma nova tendência no mercado: a transição dos bancos tradicionais para data lakes e lakehouses em operações analíticas de grande volume. Isso não significa a substituição dos bancos relacionais, mas sim uma especialização e potencialização das cargas de trabalho. Enquanto os modelos tradicionais continuam vitais para algumas empresas, as arquiteturas baseadas em serviços em nuvem começam a assumir o protagonismo em cenários onde o volume, a escalabilidade, a velocidade e a variedade da informação ditam as regras.

6.5 Adoção e impacto de Inteligência Artificial

O índice de adoção pessoal de IA/LLM no trabalho (calculado sobre a base total de respondentes por ano) é complementado pelos resultados percebidos de projetos de IA Generativa nas empresas em 2025.

Figura 8 - Gráficos de adoção de IA/LLM no trabalho (2023-2025) e resultados de projetos de IA Generativa nas empresas (2025)




O uso de ferramentas de IA/LLM no trabalho caiu de 71,3% (2023) para 60,2% (2025) da base de profissionais, trata-se de uma queda que pode refletir tanto uma redução do "hype" inicial quanto maior seletividade/maturidade no uso. No nível organizacional, o quadro é de experimentação ainda não convertida em valor: apenas 26,5% das empresas têm projetos de IA Generativa em produção gerando resultados de negócio, enquanto 38,4% seguem travadas em piloto sem resultados relevantes e 13,5% sequer iniciaram projetos. Para a instituição financeira, isso reforça que o desafio não é mais convencer a organização a testar IA, e sim converter pilotos em produção com governança e casos de uso com resultados claros e promissores.

6.6 Diferenças por região, senioridade e modelo de trabalho

A segmentação por região, modelo de trabalho e senioridade (2025) evidencia desigualdades geográficas e como o contexto de trabalho se relaciona à adoção de IA.

Figura 9 - Gráficos de salário médio por região, adoção de IA por modelo de trabalho e por senioridade (2025)




O Sudeste concentra 64,4% dos profissionais de dados do país e também paga os maiores salários médios (R\$13.380), 30% acima do Nordeste (R\$10.224), evidência de concentração geográfica de oportunidades que podem ser exploradas pelas instituições para atrair talentos remotos de outras regiões a custo mais competitivo considerando o custo de vida nas regiões. Quanto ao modelo de trabalho, profissionais remotos usam IA/LLM com muito mais frequência (71,5%) do que presenciais (56,9%), uma diferença de 14,6 pontos percentuais; e a adoção de IA cresce de acordo com a com a senioridade, sendo de de 75,3% (Júnior) a 87,7% (Especialista/Staff+), sugerindo que autonomia e experiência estão associadas a maior apropriação e uso consistente da tecnologia.

6.7 Oportunidades e desafios

As principais barreiras à adoção de IA Generativa reportadas pelas empresas (2025) e a evolução dos desafios de gestão de dados relatados por gestores (2023-2025) apontam para as oportunidades de melhoria mais imediatas.

Figura 10 - Gráficos contendo as principais barreiras à adoção de IA (2025) e evolução dos desafios de gestão de dados relatados por gestores (2023-2025)



As três maiores barreiras à adoção de IA Generativa são a falta de expertise técnica/recursos internos (38,8%), dados da empresa não prontos para uso de IA (36,8%) e falta de compreensão dos casos de uso (32,0%), percebe-se que são todas relacionadas à capacitação e maturidade de dados, não a limitações tecnológicas de mercado. A retenção de talentos foi citada como desafio por 15,8% dos gestores em 2024 e 9,5% em 2025, indicando redução da frequência dessa preocupação na amostra, melhora que pode refletir em avanços de governança, mas que ainda convive com as barreiras de IA acima, reforçando que "dados prontos para IA" (qualidade, catalogação, governança) é a oportunidade de maior alavancagem para a instituição financeira.

7. RECOMENDAÇÕES ESTRATÉGICAS E PRINCIPAIS INSIGHTS

Os dados analisados não apenas permitem compreender o cenário atual do mercado, mas também oferecem direcionamentos para decisões estratégicas relacionadas à contratação, capacitação, retenção de profissionais, adoção de novas tecnologias e geração de valor por meio de dados e inteligência artificial.

Os principais insights obtidos a partir das análises evidenciam um mercado de dados em processo de amadurecimento, mas que ainda apresenta desafios importantes relacionados à

formação, retenção e disponibilidade de profissionais. A baixa participação de profissionais juniores pode representar um risco para a sucessão e reposição de talentos, enquanto a maior valorização de áreas especializadas, como machine learning, inteligência artificial e engenharia de dados, demonstra a importância de desenvolver competências técnicas mais avançadas. Também foram identificados desafios relacionados à diversidade de gênero, à concentração regional dos profissionais e à diferença na adoção de IA entre diferentes perfis e modelos de trabalho.

Posto isso, recomenda-se que as organizações invistam na formação e evolução de profissionais, criando trilhas estruturadas de desenvolvimento que permitam a progressão de júnior para pleno e, posteriormente, para posições mais especializadas. Também é fundamental fortalecer a qualidade, a governança e a preparação dos dados para utilização em projetos de inteligência artificial, uma vez que dados preparados inadequadamente representam uma das principais barreiras para transformar experiências em resultados concretos. Além disso, políticas de equidade salarial, iniciativas de atração e retenção de mulheres em posições técnicas e a ampliação de modelos de trabalho remoto e híbrido podem contribuir para ampliar e diversificar o acesso aos talentos.

8. CONCLUSÃO

O desenvolvimento deste projeto demonstrou, na prática, a importância de um fluxo estruturado de preparação e tratamento de dados para transformar grandes volumes de informações em conhecimento capaz de apoiar decisões de negócio. A partir das três edições da pesquisa State of Data Brasil, os arquivos foram inicialmente carregados na Landing Zone do Amazon S3 e, posteriormente, ingeridos para a camada Bronze, mantendo sua estrutura próxima à original. Em seguida, passaram por processos de limpeza, padronização, harmonização dos diferentes schemas, tratamento de valores nulos e criação de variáveis na camada Silver. Por fim, na camada Gold, os dados foram agregados e organizados de acordo com as principais perguntas de negócio, permitindo a geração dos indicadores apresentados nas tabelas e gráficos finais.

Esse processo foi fundamental para que informações provenientes de diferentes anos pudessem ser comparadas de maneira consistente e transformadas em análises sobre o mercado brasileiro de dados e inteligência artificial. A utilização de AWS Glue, PySpark, Amazon S3, Glue Data Catalog e Amazon Athena possibilitou estruturar um pipeline capaz de organizar os dados desde a ingestão até sua disponibilização para análise e visualização.

Os resultados obtidos evidenciam a utilidade desse processo. Os gráficos e tabelas finais permitiram identificar um mercado em desenvolvimento, com uma participação reduzida de profissionais juniores, além de demonstrar que cargos relacionados a machine learning/IA e engenharia de dados apresentam maior remuneração, justamente em um contexto de menor disponibilidade desses profissionais. Também foi possível observar desafios relacionados à diversidade de gênero, concentração regional de talentos e diferenças na adoção de inteligência

artificial entre perfis profissionais e modelos de trabalho.

Outro insight relevante foi a identificação de uma diferença entre a experimentação e a efetiva geração de valor com IA. Embora a tecnologia esteja presente entre os profissionais, uma parcela significativa das empresas ainda permanece em estágios de piloto, enquanto apenas 26,5% delas têm projetos de IA Generativa em produção gerando resultados de negócio. As principais barreiras identificadas (falta de expertise técnica, dados não preparados para IA e falta de compreensão dos casos de uso) reforçam que a adoção de IA depende não apenas da tecnologia, mas também da qualidade e preparação dos dados, da capacitação das pessoas e da definição de objetivos de negócio claros.

Dessa forma, o projeto evidencia que, no universo de dados, a geração de valor não começa no dashboard ou no indicador final, mas na qualidade de todo o processo que transforma o dado bruto em informação confiável. A existência de camadas bem definidas, regras de transformação, padronização, catalogação e estruturas adequadas para consulta é essencial para garantir que as análises produzidas sejam consistentes e possam efetivamente apoiar decisões. Nesse contexto, a engenharia de dados funciona como a base que permite que análises, business intelligence e inteligência artificial sejam utilizadas de forma mais segura e estratégica.

9. REFERÊNCIAS BIBLIOGRÁFICAS

- AWS. **Documentação oficial dos serviços Amazon S3, AWS Glue e Amazon Athena.**
- CNN Brasil. **Mulheres na tecnologia: cenário, desafios e nomes que marcaram a história.** Disponível em: <https://www.cnnbrasil.com.br/economia/money/tecnologia/mulheres-na-tecnologia>. Acesso em 02 de setembro de 2026 às 12h50.
- DATA HACKERS. **State of Data Brasil.** Disponível em: <https://www.kaggle.com/datahackers/datasets>. Acesso em 24 de agosto de 2026 às 13h10.
- Insper. **Como escolher o melhor caminho profissional utilizando análise de dados avançada?** Disponível em: https://www.insper.edu.br/pt/conteudos/dados/como-escolher-o-melhor-caminho-profissional-utilizando-analise-de-dados-avancada?utm_source=chatgpt.com. Acesso em 22 de agosto de 2026 às 12h30.
- INSTITUTO INFORMATION MANAGEMENT. **Estudo encomendado pela Dell Technologies mostra que 73% das empresas no Brasil têm negócios orientados por dados, mas só 28% conseguem tratá-los de forma adequada.** Disponível em: https://docmanagement.com.br/08/26/2021/estudo-encomendado-pela-dell-technologies-mostra-que-73-das-empresas-no-brasil-tem-negocios-orientados-por-dados-mas-so-28-conseguem-trata-los-de-forma-adequada/?utm_source=chatgpt.com. Acesso em 22 de agosto de 2026 às 12h23.

10. LINKS DE ACESSO

- GitHub: https://github.com/gabriel07099/TechChallenge_Fase3